DATACTIVIST

Comment réaliser des datavisualisations avec R ?

Première approche - jour 2

PROGRAMME JOUR 2

1. **Introduction et discussion autour des IA**
2. **Première partie : dérouillage,** *réviser les fonctions présentées et assimilées lors de la première demi-journée, permettant la manipulation de données ;*
3. **Deuxième partie : ggplot ou comment faire de la visualisation sous R**, *appréhender la librairie de visualisation de données du tidyverse, avec des exercices de mise en pratique ;*
4. **Troisième partie : exercice final**, *reproduire une datavisualisation impliquant le traitement et la visualisation de données ;*
5. **Conclusion : vos retours, le mot de fin**.

Question sociétale

Connaissez-vous ChatGPT-3 ?

Capacité à être critique

- garder le contrôle sur le code, pouvoir vérifier le code
- Chat GPT peut halluciner du code, ne vérifie pas la sémantique de ta demande.
- Avoir le recul nécessaire pour évaluer le code sorti ==> insertion de code caché, effets de bord sur les bases de données...
- Un outil pour accélérer mais il faut quand même savoir conduire

Capacité d'introspection

Pour ChatGPT nous ne sommes pas capable aujourd'hui de certifier les propriétés de comportement du modèle. La question est : **Le chat a-t'il une morale ?**
Car finalement nous ne connaissons pas les intentions de l'IA ou plutôt de ceux qui l'ont créée

Cela rejoint le sujet de la transparence algorithmique
Attention à l'aide à la décision !

Dérouillage du matin

Exercice de mise en pratique

Vous avez 15 minutes pour effectuer ces quelques manipulations sur un jeu de données

- Depuis la base de données “***Carrefour à feu avec priorité bus***” disponible sur le portail open data de la MEL :
  - quelles sont les dimensions du jeu de données ?
  - combien y a-t-il de carrefours en poste de commandement ?

Exercice de mise en pratique

Solution

- Depuis la base de données “***Carrefour à feu avec priorité bus***” disponible sur le portail open data de la MEL :
  - quelles sont les dimensions du jeu de données ?

```
carrefour_bus <-
read_delim("https://opendata.lillemetropole.fr/api/explore/v2.1/catalog/datasets/carrefour-feu-avec-priorite-bus/exports/csv?lang=fr&timezone=Europe%2FBerlin&use_labels=true&delimiter=%3B", ";")
dim(carrefour_bus)
```

  - combien y a-t-il de carrefours en poste de commandement ?

```
table(carrefour_bus$Gestion)
```

ou

```
carrefour_bus %>% filter(Gestion == "en_PC") %>% nrow()
```

Exercice de mise en pratique

Solution

- créer un **nouvel objet** avec les carrefours de Lambersart ayant reçu plus de 50 appels un dimanche, et sommer le nombre d'appels au nombre d'actions.

```
subdf <- carrefour_bus %>% filter(Commune == "LAMBERSART",
                                  `Nombre appels` > 50,
                                  `Jour de la semaine` == "DIMANCHE") %>%
    mutate(somme_appels_actions = `Nombre appels` + `Nombre d'actions`)
```

Visualisation de données sous R

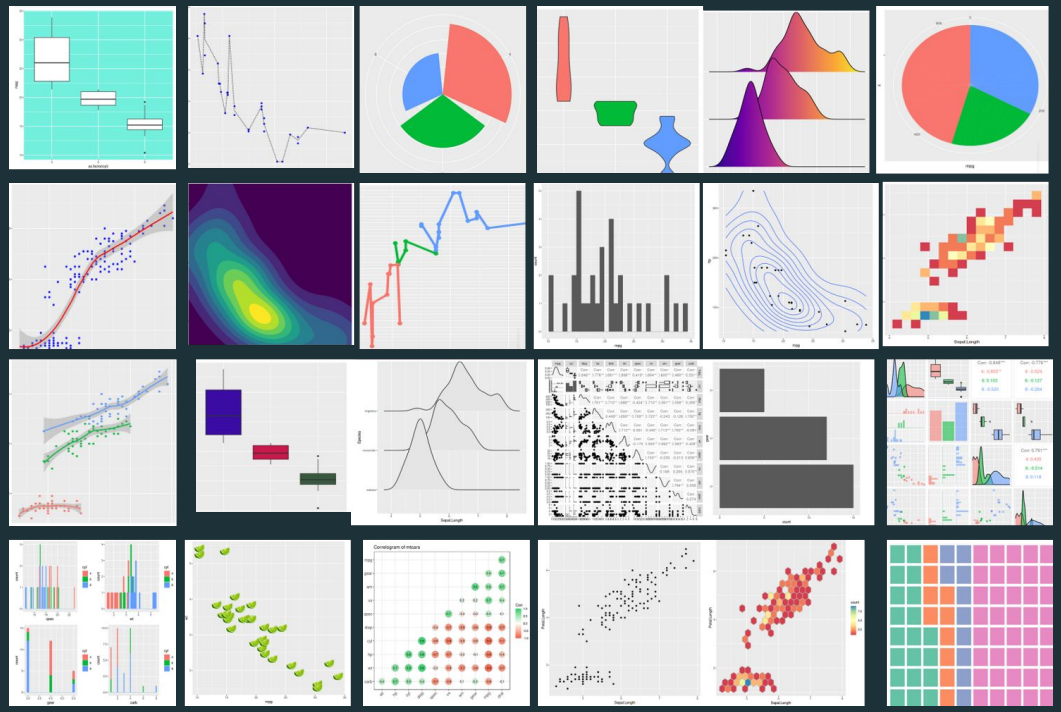

DATACTIVIST

ggplot2, LA librairie de datavisualisation

La librairie `ggplot2` contenue dans le tidyverse permet de faire des graphiques sous R. Initialement développée par Hadley Wickham, cette librairie est l'une des plus connues du tidyverse.

- **Sémantique des graphiques `ggplot2` :**
  1. `data` : les données à visualiser
  2. `aes` : les propriétés esthétiques
  3. `geom` : la géométrie/type de graphique
  4. `scale` : la gamme des valeurs
  5. `coord` : les coordonnées pour organiser la disposition
  6. `labels` : les étiquettes (noms)
  7. `facet` : les facettes pour sous-graphes
  8. `theme` : le thème appliqué aux éléments

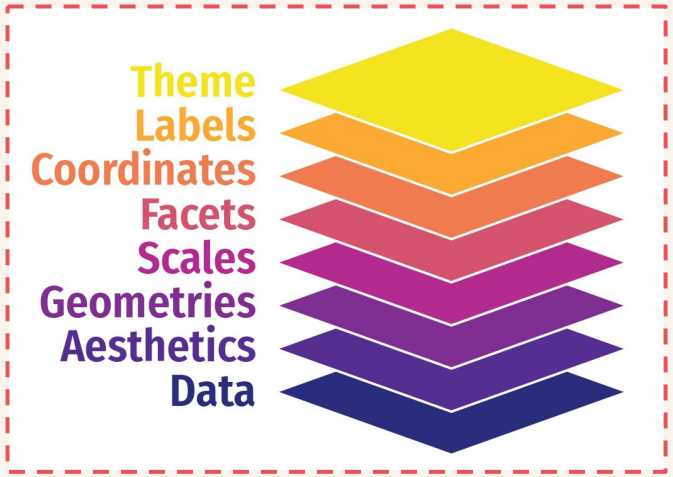

Le déroulé

`data` : les données à visualiser

`aes` : les propriétés esthétiques

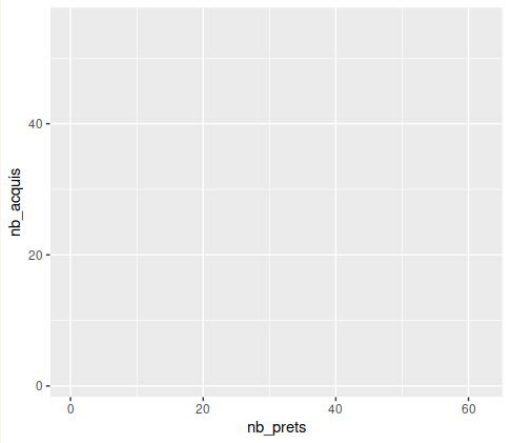

`geom` : la géométrie/type de graphique

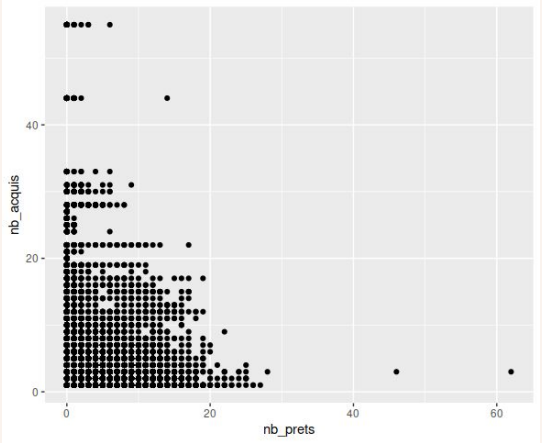

`col`, `shape` : les couleurs et les formes

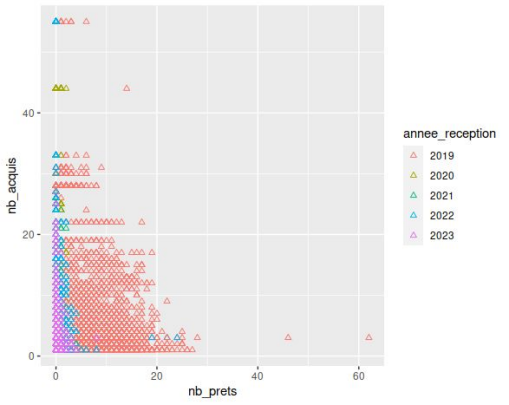

`labs` : les noms et titres

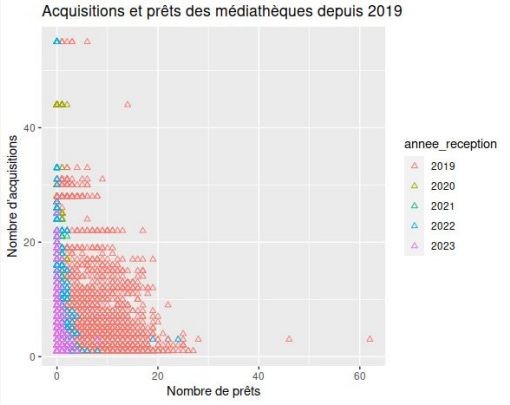

`theme` : l'apparence

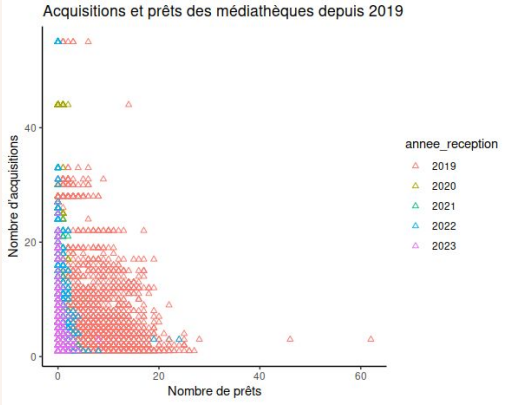

C’est parti !

Structuration de ggplot2 : `data`

Cet argument sert à appeler une base dont les données seront visualisées

- **Paramètres** :
  - `ggplot(data = data)`
  - les prochains paramètres seront ajoutés au graphique par un `+` et non par le pipe `%>%`
- **Exemple** :
  - `ggplot(exemple)` ou `exemple %>% ggplot()`

- **À vous !**
  - exécuter le code d'hier d'import et de manipulations des données de médiathèques issues du portail open data de la MEL
  - commencer un graphique ggplot2 sur la base de données chargée dans votre session R

Structuration de ggplot2 : `data`

Solution

- exécuter le code d'hier d'import et de manipulations des données de médiathèques issues du portail open data de la MEL
- commencer un graphique ggplot sur la base de données chargée dans votre session R

```
ggplot(mediatheques)
```

Structuration de ggplot2 : `aes()`

Cet argument sert à indiquer les éléments et paramètres visuels qui dépendent de variables (on parle de *mapping*)

- **Paramètres** :
  - ```
    ggplot(data = data,
           mapping = aes(x = x, y = y))
    ```
  - **x** : abscisses, axe horizontal
  - **y** : ordonnées, axe vertical
- **Exemple** :
  - `ggplot(exemple, aes(x = col1, y = col2))`

- **À vous !**
  - continuer le graphique avec le nombre de prêts en abscisses et le nombre d'acquisitions (variable créée via `mutate()`) en ordonnées
    ```

Structuration de ggplot2 : `aes()`

Solution

- continuer le graphique avec le nombre de prêts en abscisses et le nombre d'acquisitions (variable créée via `mutate()`) en ordonnées

```
ggplot(mediatheques,
       aes(x = nb_prets,
           y = nb_acquis))
```

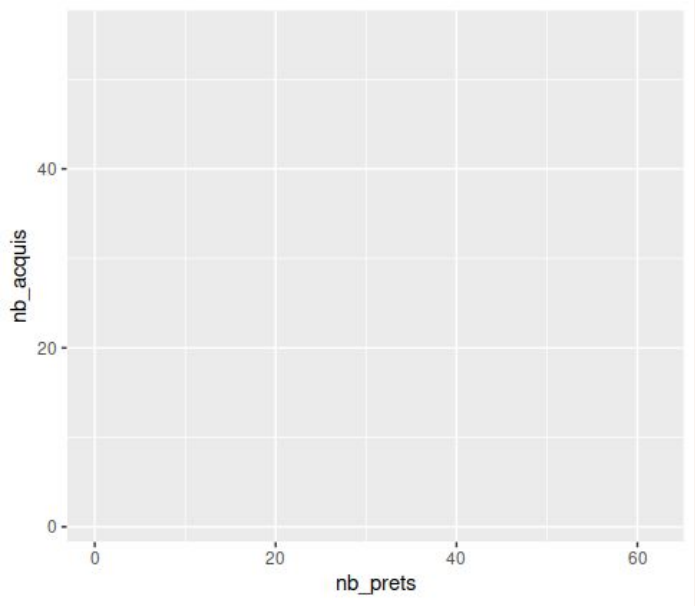

Structuration de ggplot2 : `geom_*()`

Cet argument sert à indiquer la géométrie utilisée, c'est-à-dire le type de datavisualisation

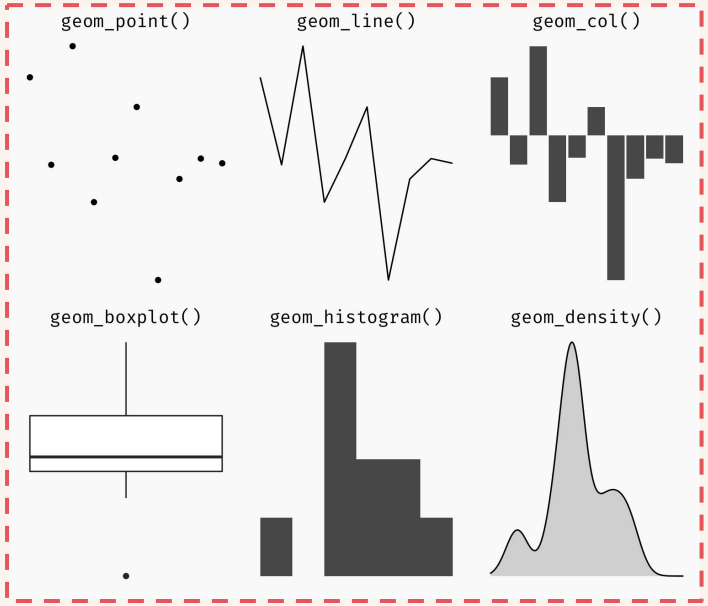

- **Paramètres** : `geom_*()`
  - `geom_point()` : nuage de points
  - `geom_line()` : ligne
  - `geom_boxplot()` : boite à moustache
  - `geom_violin()` : violon
  - `geom_density()` : densité
  - `geom_histogram()` : histogramme
  - `geom_bar()` : barres
- **Exemple** :
  -
```
ggplot(exemple,
       aes(x = col1, y = col2)) +
  geom_histogram()
```

- **À vous !**
  - continuer le graphique en ajoutant la géométrie nuage de points

Structuration de ggplot2 : `geom_*()`

Solution

- continuer le graphique en ajoutant la géométrie nuage de points

```
ggplot(mediatheques,
       aes(x = nb_prets,
           y = nb_acquis)) +
    geom_point()
```

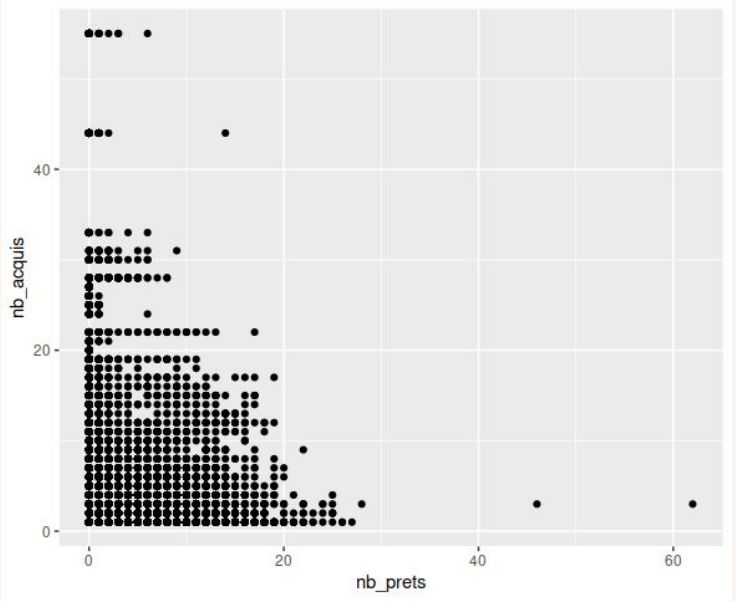

Structuration de ggplot2 : `data`, `aes`, `geom`

L'argument `aes()` peut être spécifié à différents endroits du code ; l'écriture est différente mais le résultat est identique

- **Différentes écritures** :
  - ```
    ggplot(exemple, aes(x = col1, y = col2)) +
        geom_histogram()
    ```
  - ```
    ggplot(exemple) +
          aes(x = col1, y = col2) +
          geom_histogram()
    ```
  - ```
    ggplot(exemple) +
          geom_histogram(aes(x = col1, y = col2))
    ```
    ```

Structuration de ggplot2 : `data`, `aes`, `geom`

Avec ces 3 couches essentielles, on peut “jouer” avec les paramètres pour améliorer les graphiques

- **Paramètres modifiables** :
  - `color`, `fill`, `alpha`, `size`, `shape`, `width`…
  - valeurs fixes ou dépendant de variables de la base de données
- **Exemple** :
  - ```
    ggplot(exemple,
           aes(x = col1, y = col2, size = col2),
           col = “black”, fill = “red”) +
      geom_histogram()
    ```

- **À vous !**
  - continuer le graphique en colorant les points selon l’année de réception, avec une forme de points (`shape`) égale à 2
    ```

Structuration de ggplot2 : data, aes, geom

Solution

- continuer le graphique en colorant les points selon l'année de réception, avec une forme de points (shape) égale à 2

```
ggplot(mediatheques,
       aes(x = nb_prets,
           y = nb_acquis,
           col = annee_reception)) +
   geom_point(shape = 2)
```

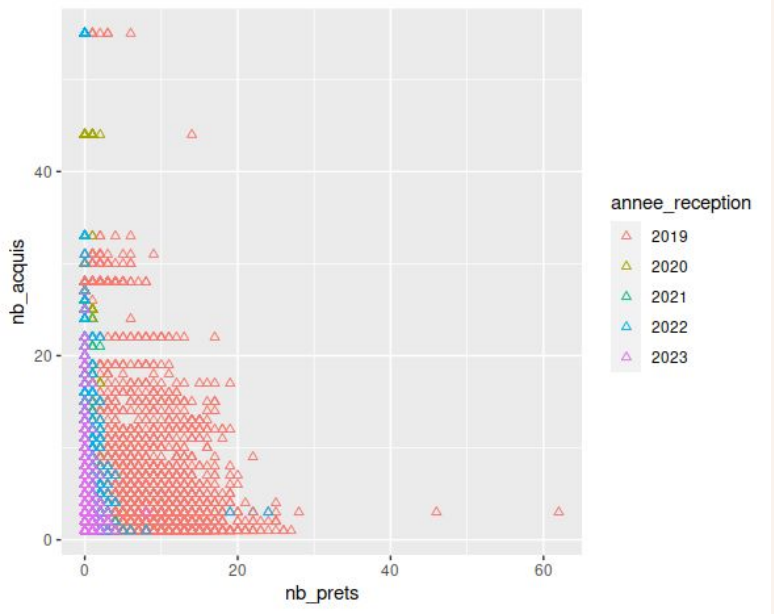

Structuration de ggplot2 : `colors`

Les couleurs des graphiques sont importantes pour l'esthétique, la lisibilité, la compréhension, et le message à faire passer

- **2 manières de renseigner les couleurs :**
  - par son nom, ex: "*red*"
  - par son code HEX, ex: "*#FFCC00*"

- **Créer sa propre couleur :**
  - https://www.color-hex.com/

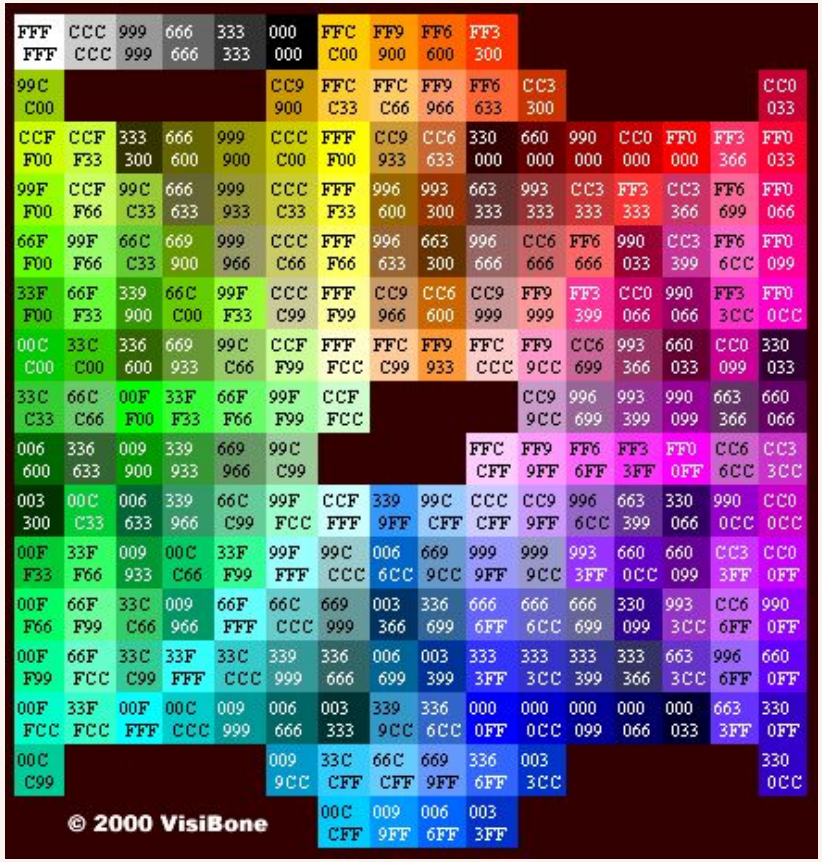

Structuration de ggplot2 : `labs()`

Cet argument sert à modifier les noms qui apparaissent sur le graphique

- **Paramètres** :
  - `labs(title, subtitle, caption, x, y)`
- **Exemple** :
  -
```
ggplot(exemple,
       aes(x = col1, y = col2)) +
   geom_histogram() +
   labs(title = "mon graphique", x = "Aa", y = "Bb")
```

- **À vous !**
  - continuer le graphique en nommant les axes X et Y, et en donnant un titre

Structuration de ggplot2 : `labs()`

Solution

- continuer le graphique en nommant les axes X et Y, et en donnant un titre

```
ggplot(mediatheques,
       aes(x = nb_prets,
           y = nb_acquis,
           col = annee_reception)) +
    geom_point(shape = 2) +
    labs(x = "Nombre de prêts",
         y = "Nombre d'acquisitions",
         title = "Acquisitions et prêts des médiathèques
        depuis 2019")
```

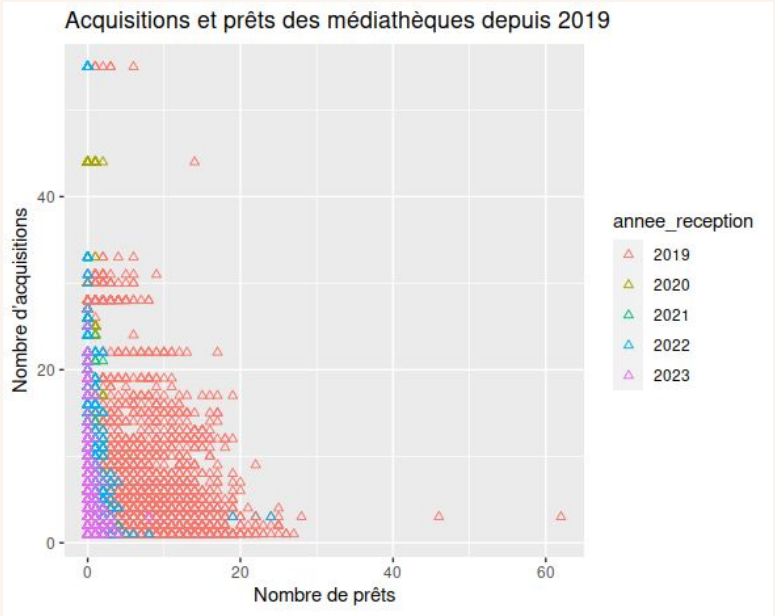

Structuration de ggplot2 : `theme_*()`

Cet argument sert à modifier l'apparence du graphique (taille, polices, couleur des titres, arrière-plan, quadrillages etc.)

- **Paramètres** :
  - `theme_*()`
  - tous les thèmes prédéfinis dans ggplot2, consultables ici
- **Exemple** :
  -
```
ggplot(exemple, aes(x = col1, y = col2)) +
    geom_histogram() +
    theme_bw()
```

- **À vous !**
  - continuer le graphique en ajoutant le thème 'classic'

Structuration de ggplot2 : theme_*()

Solution

- continuer le graphique en ajoutant le thème ‘classic’

```
ggplot(mediatheques,
       aes(x = nb_prets,
           y = nb_acquis,
           col = annee_reception)) +
   geom_point(shape = 2) +
   labs(x = "Nombre de prêts",
        y = "Nombre d’acquisitions",
        title = "Acquisitions et prêts des médiathèques
       depuis 2019") +
   theme_classic()
```

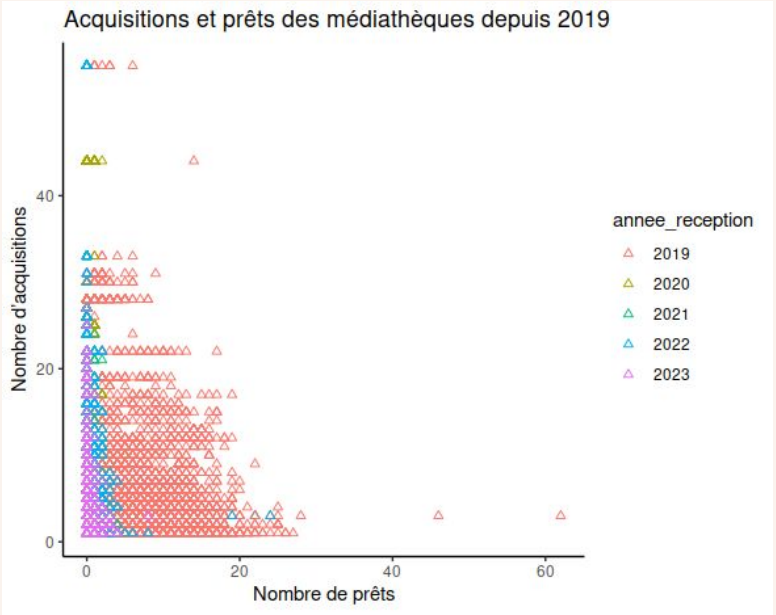

Des questions ?

Exercice final

Datavisualisation à reproduire

Vous avez une heure pour reproduire la datavisualisation suivante, en transformant et visualisant les données des médiathèques

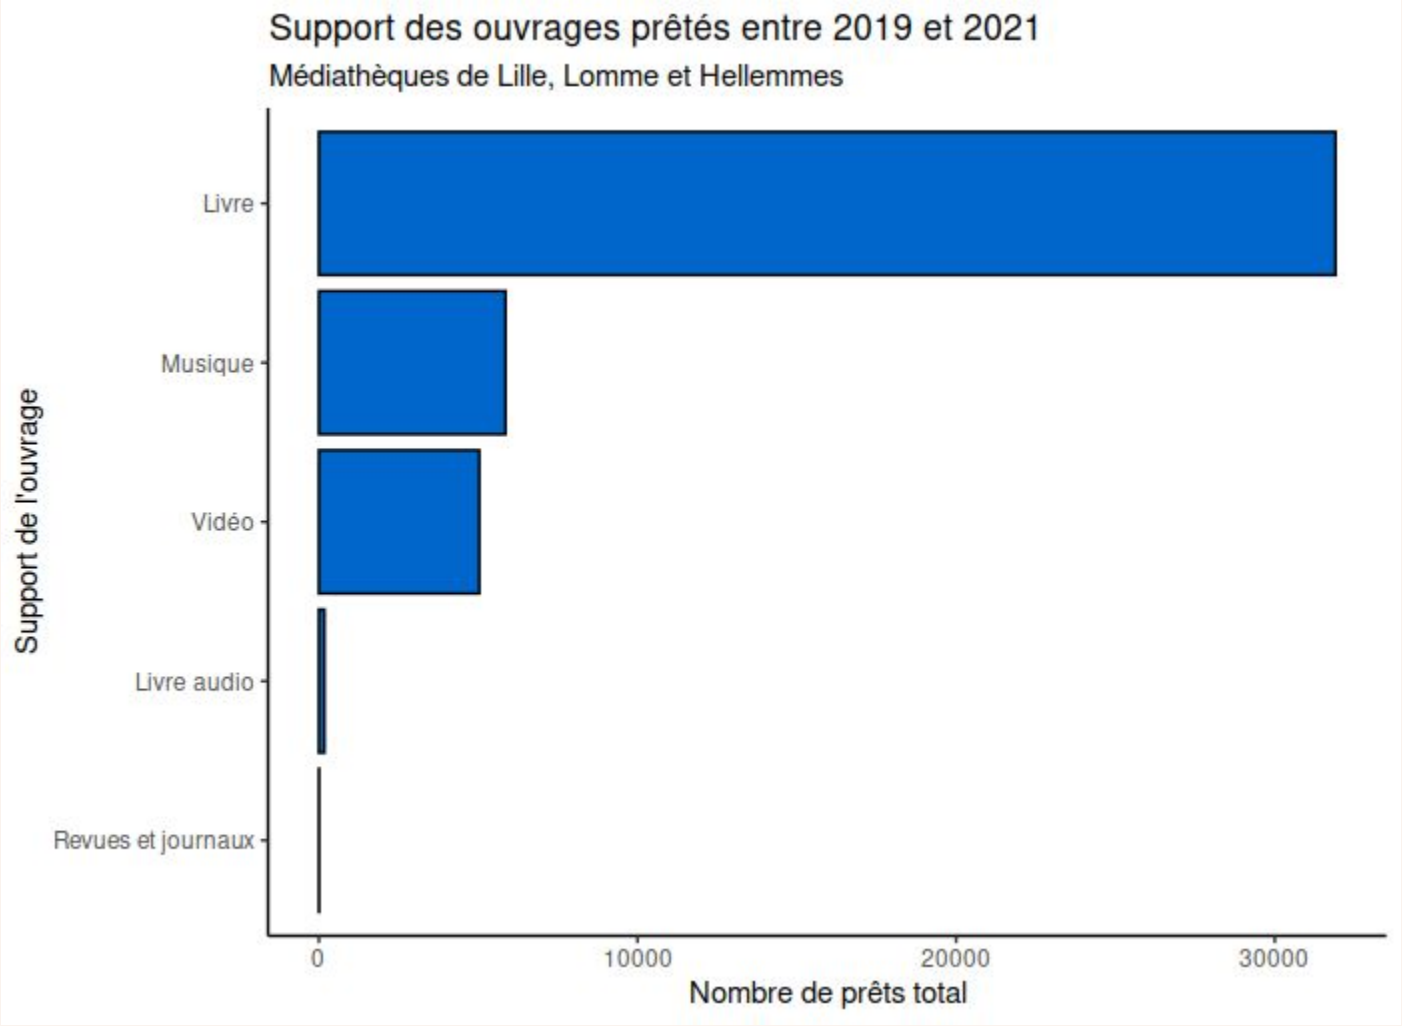

- **Avec les fonctions et paramètres présentés tout au long de cet atelier**

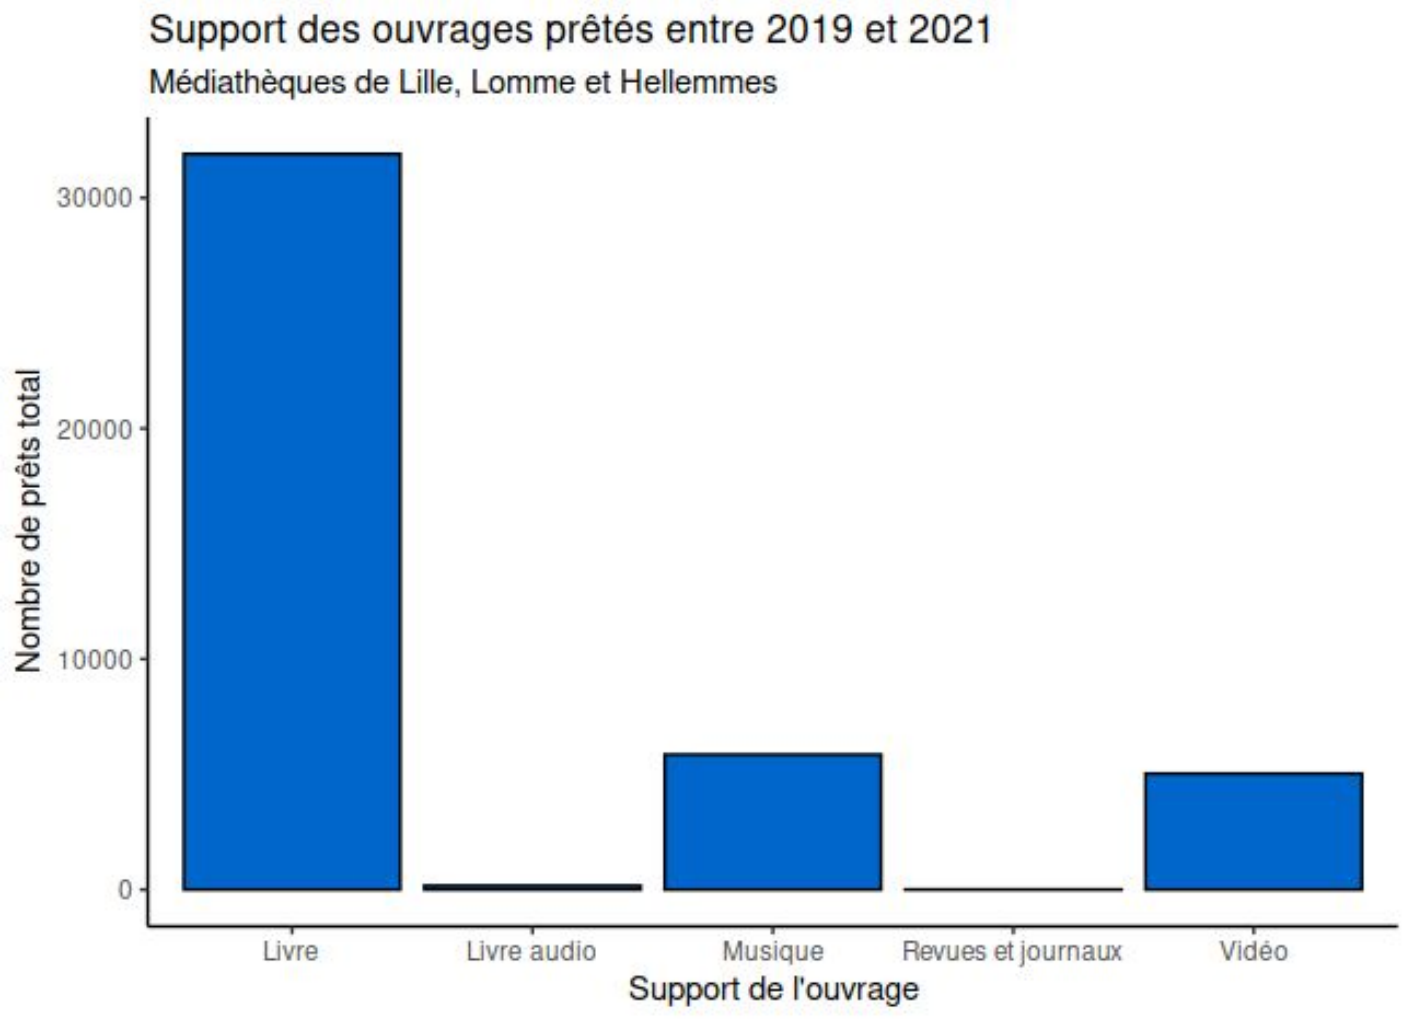

- **Avec les barres triées par nombre de prêts**

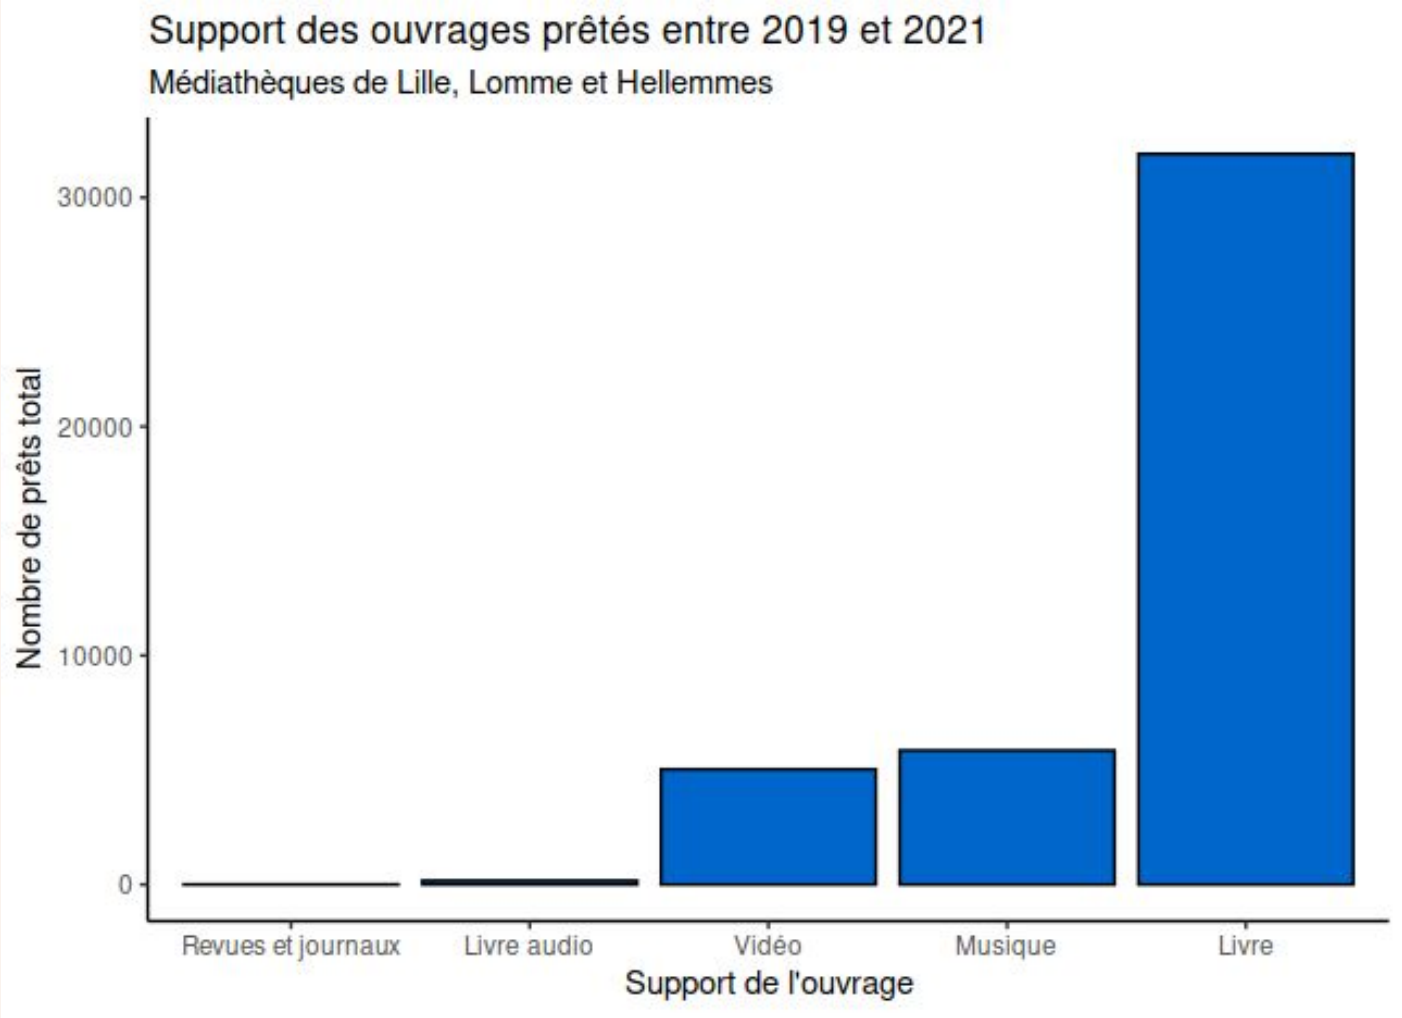

- **Avec les barres triées et à l'horizontal**

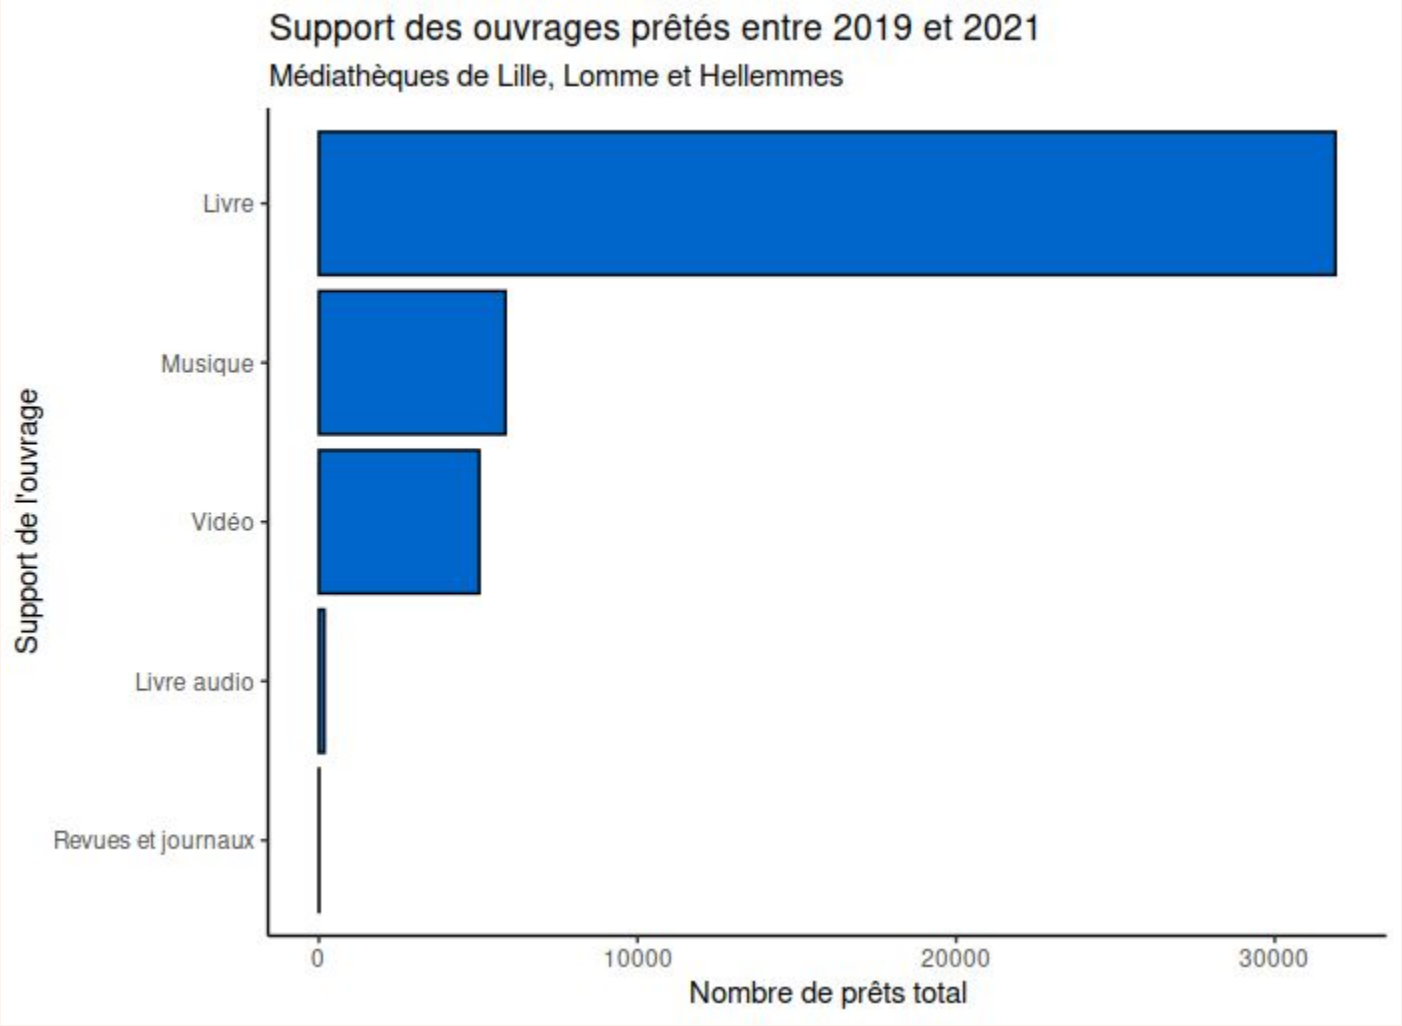

Bibliographie

Des documentations pour approfondir :

- **Cheat sheets,** “antisèches” rendant facile l’apprentissage et l’utilisation de packages R *(recharger les pages si les PDF ne s’affichent pas)* :
  - import de données
  - nettoyage de données
  - transformation de données
  - visualisation de données avec ggplot2
- **R for Data Science**, livre incontournable pour apprendre la science de données sous R, écrit par *Hadley Wickham* et *Garrett Grolemund* ;
- **R Graph Gallery,** aide et inspiration pour réaliser des graphiques sous R *;*
- **What would you like to show**, schéma récapitulatif de la visualisation à utiliser en fonction du type de données représenté.

MERCI !

diane@datactivist.coop
magalie@datactivist.coop